

# Raport nr 3

Natalia Iwańska 262270, Klaudia Janicka 262268

2023-07-02

## Zadanie 1

Table 1: Tablica dwudzielcza dla zmiennych A1 i A2.

|     |    |    |    |     |    |     |
|-----|----|----|----|-----|----|-----|
|     | -2 | -2 | 0  | 1   | 2  | Sum |
|     | 10 | 2  | 1  | 1   | 0  | 14  |
|     | 0  | 15 | 1  | 1   | 0  | 17  |
|     | 1  | 1  | 32 | 6   | 0  | 40  |
|     | 0  | 0  | 1  | 96  | 3  | 100 |
|     | 1  | 1  | 0  | 1   | 26 | 29  |
| Sum | 12 | 19 | 35 | 105 | 29 | 200 |

### Test McNemary

Nie możemy skorzystać z testu McNemary, ponieważ w tablicy na odpowiadających sobie miejscach ( $Y_{ij}$  i  $Y_{ji}$ ) występują zera, co “psuje” nam statystykę testową (wynika to wprost z jej definicji).

### Test bazujący na ilorazie wiarygodności

Korzystając z testu bazującego na ilorazie wiarygodności na poziomie istotności  $\alpha = 0.05$  otrzymana p-wartość wyniosła 0.2059752. Zatem weryfikowaną hipotezę o symetrii, która jest równoważna hipotezie o brzegowej jednorodności należy odrzucić.

## Zadanie 2

Table 2: Tablica dwudzielcza dla zmiennych W1 i W2.

|     |    |    |   |     |     |
|-----|----|----|---|-----|-----|
|     | -2 | -1 | 1 | 2   | Sum |
|     | 74 | 0  | 0 | 0   | 74  |
|     | 0  | 19 | 1 | 0   | 20  |
|     | 0  | 0  | 1 | 1   | 2   |
|     | 0  | 0  | 0 | 104 | 104 |
| Sum | 74 | 19 | 2 | 105 | 200 |

### Test McNemary

Podobnie jak w poprzednim zadaniu nie możemy skorzystać z testu McNemary, ponieważ w tablicy na odpowiadających sobie miejscach ( $Y_{ij}$  i  $Y_{ji}$ ) występują zera, co “psuje” nam statystykę testową (wynika to wprost z jej definicji).

## Test bazujący na ilorazie wiarygodności

Korzystając z testu bazującego na ilorazie wiarygodności na poziomie istotności  $\alpha = 0.05$  otrzymana p-wartość wyniosła 0.8368001. Zatem nie mamy podstaw do odrzucenia hipotezy zerowej o symetrii, która jest równoważna hipotezie o brzegowej jednorodności.

## Zadanie 3

```
##      W2  -1   1
## W1
## -1      93   1
## 1       0 106
```

```
#TEST Z
test_z <- function(tabela){
  n <- sum(rowSums(tabela))
  P <- tabela/n
  r <- rowSums(P)
  c <- colSums(P)
  D <- r[1] - c[1]
  sigma2_D <- (r[1]*(1-r[1])+c[1]*(1-c[1])-2*(P[1,1]*P[2,2]-P[1,2]*P[2,1]))/n
  Z <- D/sqrt(sigma2_D)
  p <- 2*(1 - pnorm(abs(Z)))
  return(p)
}

#TEST Z0
test_z0 <- function(tabela){
  n <- sum(rowSums(tabela))
  P <- tabela/n
  r <- rowSums(P)
  c <- colSums(P)
  D <- r[1] - c[1]
  sigma2_D0 <- (tabela[1,2]+tabela[2,1])/n^2
  Z_0 <- D/sqrt(sigma2_D0)
  p <- 2*(1 - pnorm(abs(Z_0)))
  return(p)
}
```

| test                                | p-value   |
|-------------------------------------|-----------|
| Test Z                              | 0.3160976 |
| Test Z0                             | 0.3173105 |
| McNemar test z poprawką na ciągłość | 1.0000000 |
| McNemar test bez poprawki           | 0.3173105 |

Na podstawie otrzymanych p-wartości testów przeprowadzonych na poziomie istotności  $\alpha = 0.05$  stwierdzamy, że nie mamy podstaw do odrzucenia hipotezy zerowej o symetrii, która jest równoważna hipotezie o brzegowej jednorodności.

## Zadanie 4

```
mc <- function(n, test){
  MC <- 1000
```

```

p2 <- seq(0.01,0.99,0.01)
p1 <- 0.5
m <- length(p2)
res <- rep(NA, m)
for (i in 1:m){
  counter <- 0
  for (j in 1:MC){
    X <- factor(sample(c("1","0"), n, replace=TRUE, prob = c(p1,1-p1)), levels = 0:1)
    Y <- factor(sample(c("1","0"), n, replace=TRUE, prob = c(p2[i],1-p2[i])), levels=0:1)
    tab <- ftable(X,Y)
    if (test(tab) < 0.05){
      counter <- counter+1
    }
  }
  res[i] <- counter/MC
}
return(data.frame( 'prob' = p2, 'results' = res))
}

```

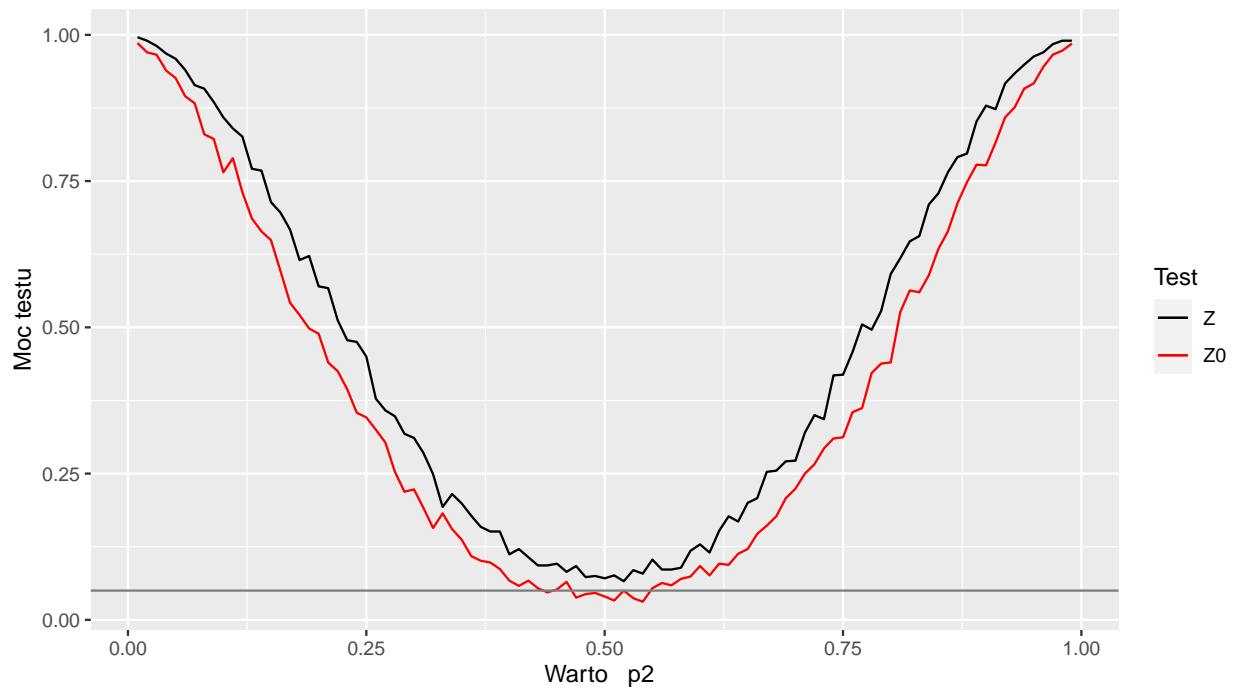


Figure 1: Wykres funkcji mocy testu  $Z$  i  $Z_0$  dla  $n = 20$




Figure 2: Wykres funkcji mocy testu  $Z$  i  $Z_0$  dla  $n = 50$





Figure 3: Wykres funkcji mocy testu  $Z$  i  $Z_0$  dla  $n = 100$



#### \* Wnioski

Na wykresach powyżej przedstawiliśmy moce testów  $Z$  i  $Z_0$  dla  $n \in \{20, 50, 100, 1000\}$ , na podstawie symulacji Monte Carlo. Szarą linią na wykresach oznaczono poziom istotności  $\alpha = 0.05$ . Funkcja mocy testu powinna przechodzić przez wartość poziomu istotności w punkcie  $p_2 = 0.5$ , ponieważ jest to miejsce, w którym oba prawdopodobieństwa są takie same, a wtedy hipoteza zerowa powinna być przyjmowana z prawdopodobieństwem  $1 - \alpha$ . Dla  $n = 20$  funkcja mocy dla testu  $Z$  jest lekko powyżej oczekiwanej wartości, ale wraz ze zwiększaniem się  $n$ , funkcja coraz bardziej zbliża się do pożądanej wartości. Można na tej podstawie wyciągnąć wniosek, że test  $Z$  jest testem asymptotycznie nieobciążonym. Dla testu  $Z_0$  sytuacja jest podobna, jednak wartość funkcji mocy dla najmniejszego rozważanego  $n$ , dla  $p_2 = 0.5$  jest trochę mniejsza niż założony poziom istotności  $\alpha$ , ale znów, ze wzrostem wartości  $n$ , zbliża się ona do poziomu istotności, więc podobnie jak przy teście  $Z$ , można wyciągnąć wniosek, że test  $Z_0$  jest testem asymptotycznie nieobciążonym. Natomiast obciążoność obydwu testów dla małych  $n$  nie jest duża. Dla zwiększających się wartości  $n$  widzimy, że wartości funkcji mocy są większe, dla  $p_2 \neq 0.5$ . Było to do przewidzenia, ponieważ wraz ze wzrastającą liczbą prób (ankietowanych), test powinien być częściej odrzucany dla  $p_1 \neq p_2$ , bo moc testu rośnie.

## Zadanie 5

Przyjmujemy za zmienną 1 zmienną  $S$  (zajmowane stanowisko), za zmienną 2 – zmienną  $W1$  (zadowolenie z wynagrodzenia w pierwszym badanym okresie) i za zmienną 3 – zmienną  $Wyk$ .

- [1 3] zmienne „S” i „Wyk” mają dowolne rozkłady oraz zmienne te są niezależne, a zmienna „W1” ma rozkład równomierny

```
model_a <- glm(Freq ~ S + Wyk,
               data = df, family = poisson)
p_a <- 1-pchisq(deviance(model_a), df = df.residual(model_a))
cbind(model_a$data, fitted = fitted(model_a))%>% kable(caption = "Porównanie wyznaczonych licznosci na p")
```

P-wartość 0 jest mniejsza niż założony poziom istotności  $\alpha$ , więc odrzucamy hipotezę zerową. Nasze dane nie pochodzą z modelu [1 3].

- [13] zmienne „S” i „Wyk” mają dowolne rozkłady oraz zmienne te nie są niezależne, a zmienna „W1”

Table 3: Porównanie wyznaczonych licznosci na podstawie modelow z rzeczywistymi licznosciami danych

| S | W1 | Wyk | Freq | fitted   |
|---|----|-----|------|----------|
| 0 | -2 | 1   | 19   | 8.86625  |
| 1 | -2 | 1   | 1    | 1.38375  |
| 0 | -1 | 1   | 3    | 8.86625  |
| 1 | -1 | 1   | 0    | 1.38375  |
| 0 | 1  | 1   | 0    | 8.86625  |
| 1 | 1  | 1   | 0    | 1.38375  |
| 0 | 2  | 1   | 18   | 8.86625  |
| 1 | 2  | 1   | 0    | 1.38375  |
| 0 | -2 | 2   | 40   | 30.27500 |
| 1 | -2 | 2   | 5    | 4.72500  |
| 0 | -1 | 2   | 15   | 30.27500 |
| 1 | -1 | 2   | 2    | 4.72500  |
| 0 | 1  | 2   | 0    | 30.27500 |
| 1 | 1  | 2   | 0    | 4.72500  |
| 0 | 2  | 2   | 68   | 30.27500 |
| 1 | 2  | 2   | 10   | 4.72500  |
| 0 | -2 | 3   | 5    | 4.10875  |
| 1 | -2 | 3   | 4    | 0.64125  |
| 0 | -1 | 3   | 0    | 4.10875  |
| 1 | -1 | 3   | 0    | 0.64125  |
| 0 | 1  | 3   | 0    | 4.10875  |
| 1 | 1  | 3   | 2    | 0.64125  |
| 0 | 2  | 3   | 5    | 4.10875  |
| 1 | 2  | 3   | 3    | 0.64125  |

Table 4: Porównanie wyznaczonych licznosci na podstawie modelow z rzeczywistymi licznosciami danych

| S | W1 | Wyk | Freq | fitted |
|---|----|-----|------|--------|
| 0 | -2 | 1   | 19   | 10.00  |
| 1 | -2 | 1   | 1    | 0.25   |
| 0 | -1 | 1   | 3    | 10.00  |
| 1 | -1 | 1   | 0    | 0.25   |
| 0 | 1  | 1   | 0    | 10.00  |
| 1 | 1  | 1   | 0    | 0.25   |
| 0 | 2  | 1   | 18   | 10.00  |
| 1 | 2  | 1   | 0    | 0.25   |
| 0 | -2 | 2   | 40   | 30.75  |
| 1 | -2 | 2   | 5    | 4.25   |
| 0 | -1 | 2   | 15   | 30.75  |
| 1 | -1 | 2   | 2    | 4.25   |
| 0 | 1  | 2   | 0    | 30.75  |
| 1 | 1  | 2   | 0    | 4.25   |
| 0 | 2  | 2   | 68   | 30.75  |
| 1 | 2  | 2   | 10   | 4.25   |
| 0 | -2 | 3   | 5    | 2.50   |
| 1 | -2 | 3   | 4    | 2.25   |
| 0 | -1 | 3   | 0    | 2.50   |
| 1 | -1 | 3   | 0    | 2.25   |
| 0 | 1  | 3   | 0    | 2.50   |
| 1 | 1  | 3   | 2    | 2.25   |
| 0 | 2  | 3   | 5    | 2.50   |
| 1 | 2  | 3   | 3    | 2.25   |

ma rozkład równomierny

```
model_b <- glm(Freq ~ S + Wyk + S*Wyk,
               data = df, family = poisson)
p_b <- 1-pchisq(deviance(model_b), df = df.residual(model_b))
cbind(model_b$data, fitted = fitted(model_b))%>% kable(caption = "Porównanie wyznaczonych licznosci na podstawie modelow z rzeczywistymi licznosciami danych")
```

P-wartość 0 jest mniejsza niż założony poziom istotności  $\alpha$ , więc odrzucamy hipotezę zerową. Nasze dane nie pochodzą z modelu [13].

- [1 2 3] zmienne „S”, „W1” i „Wyk” są wzajemnie niezależne

```
model_c <- glm(Freq ~ S + Wyk + W1,
               data = df, family = poisson)
p_c <- 1-pchisq(deviance(model_c), df = df.residual(model_c))
cbind(model_c$data, fitted = fitted(model_c))%>% kable(caption = "Porównanie wyznaczonych licznosci na podstawie modelow z rzeczywistymi licznosciami danych")
```

P-wartość  $6.18728 \times 10^{-4}$  jest mniejsza niż założony poziom istotności  $\alpha$ , więc odrzucamy hipotezę zerową. Nasze dane nie pochodzą z modelu [1 2 3].

- [123] zmienna „Wyk” jest niezależna od zmiennych „S” i „W1”, ale zmienne „S” i „W1” nie są niezależne

```
model_d <- glm(Freq ~ S + Wyk + W1 + S*W1,
               data = df, family = poisson)
p_d <- 1-pchisq(deviance(model_d), df = df.residual(model_d))
cbind(model_d$data, fitted = fitted(model_d))%>% kable(caption = "Porównanie wyznaczonych licznosci na podstawie modelow z rzeczywistymi licznosciami danych")
```

Table 5: Porównanie wyznaczonych licznosci na podstawie modelow z rzeczywistymi licznosciami danych

| S | W1 | Wyk | Freq | fitted   |
|---|----|-----|------|----------|
| 0 | -2 | 1   | 19   | 13.12205 |
| 1 | -2 | 1   | 1    | 2.04795  |
| 0 | -1 | 1   | 3    | 3.54650  |
| 1 | -1 | 1   | 0    | 0.55350  |
| 0 | 1  | 1   | 0    | 0.35465  |
| 1 | 1  | 1   | 0    | 0.05535  |
| 0 | 2  | 1   | 18   | 18.44180 |
| 1 | 2  | 1   | 0    | 2.87820  |
| 0 | -2 | 2   | 40   | 44.80700 |
| 1 | -2 | 2   | 5    | 6.99300  |
| 0 | -1 | 2   | 15   | 12.11000 |
| 1 | -1 | 2   | 2    | 1.89000  |
| 0 | 1  | 2   | 0    | 1.21100  |
| 1 | 1  | 2   | 0    | 0.18900  |
| 0 | 2  | 2   | 68   | 62.97200 |
| 1 | 2  | 2   | 10   | 9.82800  |
| 0 | -2 | 3   | 5    | 6.08095  |
| 1 | -2 | 3   | 4    | 0.94905  |
| 0 | -1 | 3   | 0    | 1.64350  |
| 1 | -1 | 3   | 0    | 0.25650  |
| 0 | 1  | 3   | 0    | 0.16435  |
| 1 | 1  | 3   | 2    | 0.02565  |
| 0 | 2  | 3   | 5    | 8.54620  |
| 1 | 2  | 3   | 3    | 1.33380  |



Table 6: Porównanie wyznaczonych licznosci na podstawie modelow z rzeczywistymi licznosciami danych

| S | W1 | Wyk | Freq | fitted |
|---|----|-----|------|--------|
| 0 | -2 | 1   | 19   | 13.120 |
| 1 | -2 | 1   | 1    | 2.050  |
| 0 | -1 | 1   | 3    | 3.690  |
| 1 | -1 | 1   | 0    | 0.410  |
| 0 | 1  | 1   | 0    | 0.000  |
| 1 | 1  | 1   | 0    | 0.410  |
| 0 | 2  | 1   | 18   | 18.655 |
| 1 | 2  | 1   | 0    | 2.665  |
| 0 | -2 | 2   | 40   | 44.800 |
| 1 | -2 | 2   | 5    | 7.000  |
| 0 | -1 | 2   | 15   | 12.600 |
| 1 | -1 | 2   | 2    | 1.400  |
| 0 | 1  | 2   | 0    | 0.000  |
| 1 | 1  | 2   | 0    | 1.400  |
| 0 | 2  | 2   | 68   | 63.700 |
| 1 | 2  | 2   | 10   | 9.100  |
| 0 | -2 | 3   | 5    | 6.080  |
| 1 | -2 | 3   | 4    | 0.950  |
| 0 | -1 | 3   | 0    | 1.710  |
| 1 | -1 | 3   | 0    | 0.190  |
| 0 | 1  | 3   | 0    | 0.000  |
| 1 | 1  | 3   | 2    | 0.190  |
| 0 | 2  | 3   | 5    | 8.645  |
| 1 | 2  | 3   | 3    | 1.235  |

Table 7: Porównanie wyznaczonych licznosci na podstawie modelow z rzeczywistymi licznosciami danych

| S | W1 | Wyk | Freq | fitted     |
|---|----|-----|------|------------|
| 0 | -2 | 1   | 19   | 14.7976879 |
| 1 | -2 | 1   | 1    | 0.3703704  |
| 0 | -1 | 1   | 3    | 4.1618497  |
| 1 | -1 | 1   | 0    | 0.0740741  |
| 0 | 1  | 1   | 0    | 0.0000000  |
| 1 | 1  | 1   | 0    | 0.0740741  |
| 0 | 2  | 1   | 18   | 21.0404624 |
| 1 | 2  | 1   | 0    | 0.4814815  |
| 0 | -2 | 2   | 40   | 45.5028902 |
| 1 | -2 | 2   | 5    | 6.2962963  |
| 0 | -1 | 2   | 15   | 12.7976879 |
| 1 | -1 | 2   | 2    | 1.2592593  |
| 0 | 1  | 2   | 0    | 0.0000000  |
| 1 | 1  | 2   | 0    | 1.2592593  |
| 0 | 2  | 2   | 68   | 64.6994220 |
| 1 | 2  | 2   | 10   | 8.1851852  |
| 0 | -2 | 3   | 5    | 3.6994220  |
| 1 | -2 | 3   | 4    | 3.3333333  |
| 0 | -1 | 3   | 0    | 1.0404624  |
| 1 | -1 | 3   | 0    | 0.6666667  |
| 0 | 1  | 3   | 0    | 0.0000000  |
| 1 | 1  | 3   | 2    | 0.6666667  |
| 0 | 2  | 3   | 5    | 5.2601156  |
| 1 | 2  | 3   | 3    | 4.3333333  |

P-wartość 0.0021231 jest mniejsza niż założony poziom istotności  $\alpha$ , więc odrzucamy hipotezę zerową. Nasze dane nie pochodzą z modelu [12 3].

- [12 13] przy ustalonej wartości zmiennej “S”, zmienne “W1” i “Wyk” są niezależne

```
model_e <- glm(Freq ~ S + Wyk + W1 + S*W1 + S*Wyk,
               data = df, family = poisson)
p_e <- 1-pchisq(deviance(model_e), df = df.residual(model_e))
cbind(model_e$data, fitted = fitted(model_e))%>% kable(caption = "Porównanie wyznaczonych licznosci na p
```

P-wartość 0.251222 jest większa niż założony poziom istotności  $\alpha$ , więc nie mamy podstaw do odrzucenia hipotezy zerowej, czyli zakładamy, że nasze dane pochodzą z modelu [12 13].

- [1 23] zmienna “S” jest niezależna od zmiennych “Wyk” i “W1”, ale zmienne “Wyk” i “W1” nie są niezależne

```
model_f <- glm(Freq ~ S + Wyk + W1 + W1*Wyk,
               data = df, family = poisson)
p_f <- 1-pchisq(deviance(model_f), df = df.residual(model_f))
cbind(model_f$data, fitted = fitted(model_f))%>% kable(caption = "Porównanie wyznaczonych licznosci na p
```

P-wartość 0.01286 jest mniejsza niż założony poziom istotności  $\alpha$ , więc odrzucamy hipotezę zerową. Nasze dane nie pochodzą z modelu [1 23].

Table 8: Porównanie wyznaczonych licznosci na podstawie modelow z rzeczywistymi licznosciami danych

| S | W1 | Wyk | Freq | fitted |
|---|----|-----|------|--------|
| 0 | -2 | 1   | 19   | 17.300 |
| 1 | -2 | 1   | 1    | 2.700  |
| 0 | -1 | 1   | 3    | 2.595  |
| 1 | -1 | 1   | 0    | 0.405  |
| 0 | 1  | 1   | 0    | 0.000  |
| 1 | 1  | 1   | 0    | 0.000  |
| 0 | 2  | 1   | 18   | 15.570 |
| 1 | 2  | 1   | 0    | 2.430  |
| 0 | -2 | 2   | 40   | 38.925 |
| 1 | -2 | 2   | 5    | 6.075  |
| 0 | -1 | 2   | 15   | 14.705 |
| 1 | -1 | 2   | 2    | 2.295  |
| 0 | 1  | 2   | 0    | 0.000  |
| 1 | 1  | 2   | 0    | 0.000  |
| 0 | 2  | 2   | 68   | 67.470 |
| 1 | 2  | 2   | 10   | 10.530 |
| 0 | -2 | 3   | 5    | 7.785  |
| 1 | -2 | 3   | 4    | 1.215  |
| 0 | -1 | 3   | 0    | 0.000  |
| 1 | -1 | 3   | 0    | 0.000  |
| 0 | 1  | 3   | 0    | 1.730  |
| 1 | 1  | 3   | 2    | 0.270  |
| 0 | 2  | 3   | 5    | 6.920  |
| 1 | 2  | 3   | 3    | 1.080  |

|           | Modele |      |                          |           |          |         |
|-----------|--------|------|--------------------------|-----------|----------|---------|
|           | [1 3]  | [13] | [1 2 3]                  | [12 3]    | [12 13]  | [1 23]  |
| P-wartość | 0      | 0    | $6.18728 \times 10^{-4}$ | 0.0021231 | 0.251222 | 0.01286 |

Table 9: P-wartości testów statystycznych

Table 10: Porównanie wyznaczonych licznosci na podstawie modeli z rzeczywistymi licznosciami danych

| S | P | Wyk | Freq | fitted  |
|---|---|-----|------|---------|
| 0 | K | 1   | 1    | 17.7325 |
| 1 | K | 1   | 0    | 2.7675  |
| 0 | M | 1   | 39   | 17.7325 |
| 1 | M | 1   | 1    | 2.7675  |
| 0 | K | 2   | 54   | 60.5500 |
| 1 | K | 2   | 4    | 9.4500  |
| 0 | M | 2   | 69   | 60.5500 |
| 1 | M | 2   | 13   | 9.4500  |
| 0 | K | 3   | 8    | 8.2175  |
| 1 | K | 3   | 4    | 1.2825  |
| 0 | M | 3   | 2    | 8.2175  |
| 1 | M | 3   | 5    | 1.2825  |

## Zadanie 6

Przyjmujemy za zmienną 1 zmienną  $S$  (zajmowane stanowisko), za zmienną 2 – zmienną  $P$  (płeć) i za zmienną 3 – zmienną  $Wyk$  (wykształcenie).

- [1 3] zmienne „S” i „Wyk” mają dowolne rozkłady oraz zmienne te są niezależne, a zmienna „P” ma rozkład równomierny

```
model_a <- glm(Freq ~ S + Wyk,
               data = df, family = poisson)
p_a <- 1-pchisq(deviance(model_a), df = df.residual(model_a))
cbind(model_a$data, fitted = fitted(model_a))%>% kable(caption = "Porównanie wyznaczonych licznosci na p
```

P-wartość  $1.6342483 \times 10^{-13}$  jest mniejsza niż założony poziom istotności  $\alpha$ , więc odrzucamy hipotezę zerową. Nasze dane nie pochodzą z modelu [1 3].

- [13] zmienne „S” i „Wyk” mają dowolne rozkłady oraz zmienne te nie są niezależne, a zmienna „P” ma rozkład równomierny

```
model_b <- glm(Freq ~ S + Wyk + S*Wyk,
               data = df, family = poisson)
p_b <- 1-pchisq(deviance(model_b), df = df.residual(model_b))
cbind(model_b$data, fitted = fitted(model_b))%>% kable(caption = "Porównanie wyznaczonych licznosci na p
```

P-wartość  $9.9507624 \times 10^{-11}$  jest mniejsza niż założony poziom istotności  $\alpha$ , więc odrzucamy hipotezę zerową. Nasze dane nie pochodzą z modelu [13].

- [1 2 3] zmienne „S”, „P” i „Wyk” są wzajemnie niezależne

```
model_c <- glm(Freq ~ S + Wyk + P,
               data = df, family = poisson)
p_c <- 1-pchisq(deviance(model_c), df = df.residual(model_c))
cbind(model_c$data, fitted = fitted(model_c))%>% kable(caption = "Porównanie wyznaczonych licznosci na p
```

Table 11: Porównanie wyznaczonych licznosci na podstawie modelow z rzeczywistymi licznosciami danych

| S | P | Wyk | Freq | fitted |
|---|---|-----|------|--------|
| 0 | K | 1   | 1    | 20.0   |
| 1 | K | 1   | 0    | 0.5    |
| 0 | M | 1   | 39   | 20.0   |
| 1 | M | 1   | 1    | 0.5    |
| 0 | K | 2   | 54   | 61.5   |
| 1 | K | 2   | 4    | 8.5    |
| 0 | M | 2   | 69   | 61.5   |
| 1 | M | 2   | 13   | 8.5    |
| 0 | K | 3   | 8    | 5.0    |
| 1 | K | 3   | 4    | 4.5    |
| 0 | M | 3   | 2    | 5.0    |
| 1 | M | 3   | 5    | 4.5    |

Table 12: Porównanie wyznaczonych licznosci na podstawie modelow z rzeczywistymi licznosciami danych

| S | P | Wyk | Freq | fitted    |
|---|---|-----|------|-----------|
| 0 | K | 1   | 1    | 12.590075 |
| 1 | K | 1   | 0    | 1.964925  |
| 0 | M | 1   | 39   | 22.874925 |
| 1 | M | 1   | 1    | 3.570075  |
| 0 | K | 2   | 54   | 42.990500 |
| 1 | K | 2   | 4    | 6.709500  |
| 0 | M | 2   | 69   | 78.109500 |
| 1 | M | 2   | 13   | 12.190500 |
| 0 | K | 3   | 8    | 5.834425  |
| 1 | K | 3   | 4    | 0.910575  |
| 0 | M | 3   | 2    | 10.600575 |
| 1 | M | 3   | 5    | 1.654425  |

Table 13: Porównanie wyznaczonych licznosci na podstawie modelow z rzeczywistymi licznosciami danych

| S | P | Wyk | Freq | fitted |
|---|---|-----|------|--------|
| 0 | K | 1   | 1    | 12.915 |
| 1 | K | 1   | 0    | 1.640  |
| 0 | M | 1   | 39   | 22.550 |
| 1 | M | 1   | 1    | 3.895  |
| 0 | K | 2   | 54   | 44.100 |
| 1 | K | 2   | 4    | 5.600  |
| 0 | M | 2   | 69   | 77.000 |
| 1 | M | 2   | 13   | 13.300 |
| 0 | K | 3   | 8    | 5.985  |
| 1 | K | 3   | 4    | 0.760  |
| 0 | M | 3   | 2    | 10.450 |
| 1 | M | 3   | 5    | 1.805  |

Table 14: Porównanie wyznaczonych licznosci na podstawie modelow z rzeczywistymi licznosciami danych

| S | P | Wyk | Freq | fitted     |
|---|---|-----|------|------------|
| 0 | K | 1   | 1    | 14.5664740 |
| 1 | K | 1   | 0    | 0.2962963  |
| 0 | M | 1   | 39   | 25.4335260 |
| 1 | M | 1   | 1    | 0.7037037  |
| 0 | K | 2   | 54   | 44.7919075 |
| 1 | K | 2   | 4    | 5.0370370  |
| 0 | M | 2   | 69   | 78.2080925 |
| 1 | M | 2   | 13   | 11.9629630 |
| 0 | K | 3   | 8    | 3.6416185  |
| 1 | K | 3   | 4    | 2.6666667  |
| 0 | M | 3   | 2    | 6.3583815  |
| 1 | M | 3   | 5    | 6.3333333  |

P-wartość  $1.2979651 \times 10^{-10}$  jest mniejsza niż założony poziom istotności  $\alpha$ , więc odrzucamy hipotezę zerową. Nasze dane nie pochodzą z modelu [1 2 3].

- [12 3] zmienna “Wyk” jest niezależna od zmiennych “S” i “P”, ale zmienne “S” i “P” nie są niezależne

```
model_d <- glm(Freq ~ S + Wyk + P + S*P,
               data = df, family = poisson)
p_d <- 1-pchisq(deviance(model_d), df = df.residual(model_d))
cbind(model_d$data, fitted = fitted(model_d))%>% kable(caption = "Porównanie wyznaczonych licznosci na podstawie modelow z rzeczywistymi licznosciami danych")
```

P-wartość  $4.8342885 \times 10^{-11}$  jest mniejsza niż założony poziom istotności  $\alpha$ , więc odrzucamy hipotezę zerową. Nasze dane nie pochodzą z modelu [12 3].

- [12 13] przy ustalonej wartości zmiennej “S”, zmienne “P” i “Wyk” są niezależne

```
model_e <- glm(Freq ~ S + Wyk + P + S*P + S*Wyk,
               data = df, family = poisson)
p_e <- 1-pchisq(deviance(model_e), df = df.residual(model_e))
cbind(model_e$data, fitted = fitted(model_e))%>% kable(caption = "Porównanie wyznaczonych licznosci na podstawie modelow z rzeczywistymi licznosciami danych")
```

P-wartość  $3.0176519 \times 10^{-8}$  jest mniejsza niż założony poziom istotności  $\alpha$ , więc odrzucamy hipotezę zerową. Nasze dane nie pochodzą z modelu [12 13].

Table 15: Porównanie wyznaczonych licznosci na podstawie modelow z rzeczywistymi licznosciami danych

| S | P | Wyk | Freq | fitted |
|---|---|-----|------|--------|
| 0 | K | 1   | 1    | 0.865  |
| 1 | K | 1   | 0    | 0.135  |
| 0 | M | 1   | 39   | 34.600 |
| 1 | M | 1   | 1    | 5.400  |
| 0 | K | 2   | 54   | 50.170 |
| 1 | K | 2   | 4    | 7.830  |
| 0 | M | 2   | 69   | 70.930 |
| 1 | M | 2   | 13   | 11.070 |
| 0 | K | 3   | 8    | 10.380 |
| 1 | K | 3   | 4    | 1.620  |
| 0 | M | 3   | 2    | 6.055  |
| 1 | M | 3   | 5    | 0.945  |

- [1 23] zmienna “S” jest niezalezna od zmiennych “Wyk” i “P”, ale zmienne “Wyk” i “P” nie sa niezalezne

```
model_f <- glm(Freq ~ S + Wyk + P + P*Wyk,
               data = df, family = poisson)
p_f <- 1-pchisq(deviance(model_f), df = df.residual(model_f))
cbind(model_f$data, fitted = fitted(model_f))%>% kable(caption = "Porównanie wyznaczonych licznosci na podstawie modelow z rzeczywistymi licznosciami danych")
```

P-wartość  $1.7468073 \times 10^{-4}$  jest mniejsza niż założony poziom istotności  $\alpha$ , więc odrzucamy hipotezę zerową. Nasze dane nie pochodzą z modelu [1 23].

|           | Modele                      |                             |                             |                             |                            |               |
|-----------|-----------------------------|-----------------------------|-----------------------------|-----------------------------|----------------------------|---------------|
|           | [1 3]                       | [13]                        | [1 2 3]                     | [12 3]                      | [12 13]                    | [1 2 3 12 13] |
| P-wartość | $1.6342483 \times 10^{-13}$ | $9.9507624 \times 10^{-11}$ | $1.2979651 \times 10^{-10}$ | $4.8342885 \times 10^{-11}$ | $3.0176519 \times 10^{-8}$ | 1.746         |

Table 16: P-wartości testów statystycznych

## Zadanie 7

Do zmiennych  $S$ ,  $W1$  i  $Wyk$  przyjmujemy model log-liniowy [13 23] oraz [123] i na tej podstawie obliczymy prawdopodobieństwa.

- Prawdopodobieństwo, że osoba pracująca na stanowisku kierowniczym jest zdecydowanie zadowolona ze swojego wynagrodzenia.

Przykładowy kod obliczający to prawdopodobieństwo dla modelu [13 23]:

```
sum(result1$fitted(model1)[result1$S == 1 & result1$W1 == 2])/(sum(result1$fitted(model1)[result1$S == 1]))
## [1] 0.5074047
```

|                    | Prawdopodobieństwo |
|--------------------|--------------------|
| Wartość empiryczna | 0.4814815          |
| Model [13 23]      | 0.5074047          |
| Model [123]        | 0.4814815          |

Table 17: Oszacowane prawdopodobieństwa

Na podstawie wyników przedstawionych w tabeli możemy zauważyć, że do naszych danych lepiej niż model

[13 23] dopasował się model [123] - prawdopodobieństwo obliczone z wykorzystaniem tego modelu jest identyczne jak prawdopodobieństwo empiryczne.

- Prawdopodobieństwo, że osoba z wykształceniem zawodowym pracuje na stanowisku kierowniczym.

|                    | Prawdopodobieństwo |
|--------------------|--------------------|
| Wartość empiryczna | 0.0243902          |
| Model [13 23]      | 0.0243902          |
| Model [123]        | 0.0243902          |

Table 18: Oszacowane prawdopodobieństwa

Prawdopodobieństwa obliczone z wykorzystaniem obu modeli są identyczne jak prawdopodobieństwo empiryczne. Okazuje się, że prawdopodobieństwo, że osoba z wykształceniem zawodowym pracuje na na stanowisku kierowniczym jest niezwykle małe.

- Prawdopodobieństwo, że osoba z wykształceniem wyższym nie pracuje na stanowisku kierowniczym.

|                    | Prawdopodobieństwo |
|--------------------|--------------------|
| Wartość empiryczna | 0.5263158          |
| Model [13 23]      | 0.5263158          |
| Model [123]        | 0.5263158          |

Table 19: Oszacowane prawdopodobieństwa

Znów prawdopodobieństwa obliczone z wykorzystaniem modeli są identyczne jak prawdopodobieństwo empiryczne.

## Zadanie 8

Do zmiennych  $S$ ,  $P$  i  $Wyk$  przyjmiemy model log-liniowy [13 23] i na tej podstawie obliczymy prawdopodobieństwo.

- Prawdopodobieństwo, że osoba pracująca na stanowisku kierowniczym jest kobietą.

Przykładowe wywołanie:

```
m <- sum(result$`fitted(model)`[result$S == 1 & result$P == 'K'])/(sum(result$`fitted(model)`[result$S == 1]))
emp <- sum(result$Freq[result$S == 1 & result$P == 'K'])/(sum(result$Freq[result$S == 1]))
```

|                    | Prawdopodobieństwo |
|--------------------|--------------------|
| Wartość empiryczna | 0.4722762          |
| Model [13 23]      | 0.2962963          |

Table 20: Oszacowane prawdopodobieństwa

Prawdopodobieństwo uzyskane z wykorzystaniem modelu [13 23] dość mocno odbiegają od otrzymanego wyniku empirycznego.

- Prawdopodobieństwo, że osoba z wykształceniem zawodowym pracuje na stanowisku kierowniczym.



|                    | Prawdopodobieństwo |
|--------------------|--------------------|
| Wartość empiryczna | 0.0243902          |
| Model [13 23]      | 0.0243902          |

Table 21: Oszacowane prawdopodobieństwa

Prawdopodobieństwo otrzymane za pomocą modelu jest identyczne jak to otrzymane z wykorzystaniem modelu.

|           | Prawdopodobieństwo     |
|-----------|------------------------|
| Zadanie 7 | 0.0243902 <sup>*</sup> |
| Zadanie 8 | 0.0243902              |

Table 22: Porównanie prawdopodobieństw tego samego problemu uzyskanych w zadaniu 7. i 8.

Prawdopodobieństwa tego samego problemu z zadania 7. i 8. otrzymane za pomocą różnych modeli log-liniowych są identyczne.

- Prawdopodobieństwo, że osoba z wykształceniem wyższym jest mężczyzną.

|                    | Prawdopodobieństwo |
|--------------------|--------------------|
| Wartość empiryczna | 0.3684211          |
| Model [13 23]      | 0.3684211          |

Table 23: Oszacowane prawdopodobieństwa

Prawdopodobieństwo otrzymane za pomocą modelu jest identyczne jak to otrzymane z wykorzystaniem modelu.

## Zadanie 9

W tym zadaniu będziemy testować hipotezy zerowe przeciwko dwóm pewnym modelom, w których jeden jest pełny (zawierają wszystkie interakcje) a drugi jest nadmodelem modelu z hipotezy zerowej, ale nie jest modelem pełnym. Hipotezy testujemy na poziomie istotności  $\alpha = 0.05$ .

- $H_0$ : Dane pochodzą z modelu [1 2 3] przeciwko
- $H_1$ : Dane pochodzą z modelu pełnego [123]
- $H_1$ : Dane pochodzą z modelu [12 3]

Przykładowy kod, w którym dopasowujemy modele do naszych danych:

```
m_0 <- glm(Freq ~ S+W1+Wyk, data = df_W1, family = poisson)
m_1 <- glm(Freq ~ S+W1+Wyk+S*W1+Wyk*W1+S*Wyk+S*W1*Wyk, data = df_W1, family = poisson)
m_2 <- glm(Freq ~ S+W1+Wyk+S*W1, data = df_W1, family = poisson)
```

Prawdopodobieństwo dla pierwszej z hipotez alternatywnych  $6.18728 \times 10^{-4}$  oraz dla drugiej 0.0396896 są mniejsze niż założony poziom istotności  $\alpha$ , więc odrzucamy hipotezę zerową.

- $H_0$ : Dane pochodzą z modelu [2 13] przeciwko
- $H_1$ : Dane pochodzą z modelu [123]
- $H_1$ : Dane pochodzą z modelu [13 23]

```

m_0 <- glm(Freq ~ S+W1+Wyk+ S*Wyk, data = df_W1, family = poisson)
m_1 <- glm(Freq ~ S+W1+Wyk+S*W1+Wyk*W1+S*Wyk+S*W1*Wyk, data = df_W1, family = poisson)
m_2 <- glm(Freq ~ S+W1+Wyk+Wyk*W1+S*Wyk, data = df_W1, family = poisson)

test <- anova(m_0, m_1)
p_1 <- 1-pchisq(test$Deviance[2], df = test$Df[2])

test <- anova(m_0, m_2)
p_2 <- 1-pchisq(test$Deviance[2], df = test$Df[2])

```

Prawdopodobieństwo dla pierwszej z hipotez alternatywnych 0.0809632 jest większe niż założony poziom istotności, więc nie odrzucamy hipotezy zerowej. Natomiast dla drugiej 0.0055869 jest mniejszy niż założony poziom istotności  $\alpha$ , więc odrzucamy hipotezę zerową.

- $H_0$ : Dane pochodzą z modelu [13 23] przeciwko
- $H_1$ : Dane pochodzą z modelu [123]
- $H_1$ : Dane pochodzą z modelu [12 13 23]

```

m_0 <- glm(Freq ~ S+W1+Wyk+ S*Wyk+W1*Wyk, data = df_W1, family = poisson)
m_1 <- glm(Freq ~ S+W1+Wyk+S*W1+Wyk*W1+S*Wyk+S*W1*Wyk, data = df_W1, family = poisson)
m_2 <- glm(Freq ~ S+W1+Wyk+S*W1+Wyk*W1+S*Wyk+S*W1, data = df_W1, family = poisson)

test <- anova(m_0, m_1)
p_1 <- 1-pchisq(test$Deviance[2], df = test$Df[2])

test <- anova(m_0, m_2)
p_2 <- 1-pchisq(test$Deviance[2], df = test$Df[2])

```

Prawdopodobieństwo dla pierwszej z hipotez alternatywnych 0.8446445 oraz dla drugiej 0.349985 jest większe niż założony poziom istotności, więc nie mamy podstaw do odrzucenia hipotezy zerowej.

- $H_0$ : Dane pochodzą z modelu [13 23] przeciwko
- $H_1$ : Dane pochodzą z modelu [123]
- $H_1$ : Dane pochodzą z modelu [12 13 23]

```

m_0 <- glm(Freq ~ S+P+Wyk+S*Wyk+P*Wyk, data = df_P, family = poisson)
m_1 <- glm(Freq ~ S+P+Wyk+S*P+Wyk*P+S*Wyk+S*P*Wyk, data = df_P, family = poisson)
m_2 <- glm(Freq ~ S+P+Wyk+S*P+Wyk*P+S*Wyk+S*P, data = df_P, family = poisson)

test <- anova(m_0, m_1)
p_1 <- 1-pchisq(test$Deviance[2], df = test$Df[2])

test <- anova(m_0, m_2)
p_2 <- 1-pchisq(test$Deviance[2], df = test$Df[2])

```

Prawdopodobieństwo dla drugiej z hipotez alternatywnych 0.0244872 jest mniejszy niż założony poziom istotności  $\alpha$ , więc odrzucamy hipotezę zerową. Natomiast dla pierwszej 0.1446957 jest mniejszy, zatem nie mamy podstaw do odrzucenia hipotezy zerowej.

## Zadanie 10

### Testy

Wybór modelu w oparciu o testy został wykonany w ten sposób, że najpierw wzięliśmy model, w którym nie występują żadne interakcje [1 2 3], wykonaliśmy test ilorazu wiarygodności, gdzie hipotezą alternatywną  $H_1$  był nadmodel modelu z hipotezy alternatywnej. Jeśli uzyskana p-wartość była większa niż założony

poziom istotności  $\alpha = 0.05$ , to przyjmowaliśmy że model z hipotezy zerowej  $H_0$  lepiej opisuje nasze dane, w przeciwnym wypadku, dla następnych testów, model z hipotezy alternatywnej stawał się modelem hipotezy zerowej. Postępując w ten sposób doszliśmy do modelu, który według testów najlepiej opisuje dane.

- Model [1 2 3] przeciwko [12 3]

```
df <- as.data.frame(ftable(personel$A1,personel$W1,personel$P))
names(df) <- c('A1', 'W1', 'P', 'Freq')

m_0 <- glm(Freq ~ A1+W1+P, data = df, family = poisson)
m_1 <- glm(Freq ~ A1+W1+W1+A1*W1, data = df, family = poisson)
test <- anova(m_0, m_1)
p_2 <- 1-pchisq(test$Deviance[2], df = test$Df[2])
```

Otrzymana p-wartość 0 jest mniejsza niż założony poziom istotności, więc odrzucamy hipotezę zerową. Model [12 3] staje się modelem wyjściowym.

- Model [12 3] przeciwko [12 13]

```
m_0 <- glm(Freq ~ A1+W1+P+A1*W1, data = df, family = poisson)
m_1 <- glm(Freq ~ A1+W1+P+A1*W1+A1*P, data = df, family = poisson)
test <- anova(m_0, m_1)
p_2 <- 1-pchisq(test$Deviance[2], df = test$Df[2])
```

Otrzymana p-wartość 0.8022519 jest większa niż założony poziom istotności, więc nie mamy podstaw do odrzucenia hipotezy zerowej.

- Model [12 3] przeciwko [12 23]

```
m_0 <- glm(Freq ~ A1+W1+P+A1*W1, data = df, family = poisson)
m_1 <- glm(Freq ~ A1+W1+P+A1*W1+W1*P, data = df, family = poisson)
test <- anova(m_0, m_1)
p_2 <- 1-pchisq(test$Deviance[2], df = test$Df[2])
```

Otrzymana p-wartość 0.5349822 jest większa niż założony poziom istotności, więc nie mamy podstaw do odrzucenia hipotezy zerowej.

- Model [12 3] przeciwko [12 13 23]

```
m_0 <- glm(Freq ~ A1+W1+P+A1*W1, data = df, family = poisson)
m_1 <- glm(Freq ~ A1+W1+P+A1*W1+W1*P+P*A1, data = df, family = poisson)
test <- anova(m_0, m_1)
p_2 <- 1-pchisq(test$Deviance[2], df = test$Df[2])
```

Otrzymana p-wartość 0.775001 jest większa niż założony poziom istotności, więc nie mamy podstaw do odrzucenia hipotezy zerowej.

- Model [12 3] przeciwko [123]

```
m_0 <- glm(Freq ~ A1+W1+P+A1*W1, data = df, family = poisson)
m_1 <- glm(Freq ~ A1+W1+P+A1*W1+W1*P+P*A1+A1*W1*P, data = df, family = poisson)
test <- anova(m_0, m_1)
p_2 <- 1-pchisq(test$Deviance[2], df = test$Df[2])
```

Otrzymana p-wartość 0.9093978 jest większa niż założony poziom istotności, więc nie mamy podstaw do odrzucenia hipotezy zerowej.

Z przeprowadzonych testów wynika, że model [12 3] najlepiej opisuje nasze dane.

## Kryterium AIC

```
models_AIC <- c(AIC(model_), AIC(model_1), AIC(model_2), AIC(model_3),  
AIC(model_1_2), AIC(model_1_3), AIC(model_2_3), AIC(model_12),  
AIC(model_13), AIC(model_23), AIC(model_1_2_3), AIC(model_12_3),  
AIC(model_13_2), AIC(model_1_23), AIC(model_12_23), AIC(model_13_23),  
AIC(model_12_13), AIC(model_12_23_13), AIC(model_123))
```

| Model      | Wartość kryterium |
|------------|-------------------|
| [ ]        | 582.2529387       |
| [1]        | 484.1343098       |
| [2]        | 427.4253204       |
| [3]        | 567.1888702       |
| [1 2]      | 329.3066915       |
| [1 3]      | 469.0702413       |
| [2 3]      | 412.3612519       |
| [12]       | 138.6563749       |
| [13]       | 475.4339317       |
| [23]       | 416.1766225       |
| [1 2 3]    | 314.242623        |
| [12 3]     | 123.5923063       |
| [13 2]     | 320.6063134       |
| [1 23]     | 318.0579936       |
| [12 23]    | 127.4076769       |
| [13 23]    | 324.421684        |
| [12 13]    | 129.9559967       |
| [12 13 23] | 133.5509426       |
| [123]      | 150.1855778       |

Table 24: Wartości obliczonych kryteriów AIC dla poszczególnych modeli

Najmniejsza wartość kryterium informacyjnego wynosi 123.5923063, a otrzymano ją dla modelu [12 3], czyli tego samego który otrzymaliśmy z wykorzystaniem testów.

## Kryterium BIC

```
models_BIC <- c(BIC(model_), BIC(model_1), BIC(model_2), BIC(model_3),  
BIC(model_1_2), BIC(model_1_3), BIC(model_2_3), BIC(model_12),  
BIC(model_13), BIC(model_23), BIC(model_1_2_3), BIC(model_12_3),  
BIC(model_13_2), BIC(model_1_23), BIC(model_12_23), BIC(model_13_23),  
BIC(model_12_13), BIC(model_12_23_13), BIC(model_123))
```

| Model      | Wartość kryterium |
|------------|-------------------|
| [ ]        | 583.9418182       |
| [1]        | 492.578707        |
| [2]        | 434.1808382       |
| [3]        | 570.5666291       |
| [1 2]      | 342.8177271       |
| [1 3]      | 479.203518        |
| [2 3]      | 420.8056492       |
| [12]       | 172.4339639       |
| [13]       | 492.3227263       |
| [23]       | 429.6876582       |
| [1 2 3]    | 329.4425381       |
| [12 3]     | 159.0587748       |
| [13 2]     | 342.5617463       |
| [1 23]     | 338.324547        |
| [12 23]    | 167.9407838       |
| [13 23]    | 351.4437553       |
| [12 13]    | 172.1779831       |
| [12 13 23] | 180.8395673       |
| [123]      | 217.740756        |

Table 25: Wartości obliczonych kryteriów BIC dla poszczególnych modeli

Najmniejsza wartość kryterium informacyjnego wynosi 159.0587748, a otrzymano ją dla modelu [12 3], czyli tego samego który otrzymaliśmy z wykorzystaniem testów i kryterium AIC.

## Metoda krokowa

```
step(model_123)
```

```
## Start:  AIC=150.19
## Freq ~ A1 + W1 + P + A1 * W1 + A1 * P + W1 * P + A1 * W1 * P
##
##           Df Deviance    AIC
## - A1:W1:P 12    7.3654 133.55
## <none>          0.0000 150.19
##
## Step:  AIC=133.55
## Freq ~ A1 + W1 + P + A1:W1 + A1:P + W1:P
##
##           Df Deviance    AIC
## - A1:P     4     9.222 127.41
## - W1:P     3     9.770 129.96
## <none>          7.365 133.55
## - A1:W1  12   222.236 324.42
##
## Step:  AIC=127.41
## Freq ~ A1 + W1 + P + A1:W1 + W1:P
##
##           Df Deviance    AIC
## - W1:P     3    11.407 123.59
## <none>          9.222 127.41
## - A1:W1  12   223.872 318.06
```

```
##
## Step:  AIC=123.59
## Freq ~ A1 + W1 + P + A1:W1
##
##           Df Deviance    AIC
## <none>         11.407 123.59
## - P           1    28.471 138.66
## - A1:W1       12   226.057 314.24

##
## Call:  glm(formula = Freq ~ A1 + W1 + P + A1:W1, family = poisson, data = df)
##
## Coefficients:
## (Intercept)      A1-1          A10          A11          A12          W1-1
##      1.5293      0.2076      1.0986     -1.4663     -1.4663     -22.1342
##           W11           W12           PM      A1-1:W1-1      A10:W1-1      A11:W1-1
##      -2.5649     -22.1342      0.5971     -0.2076     -1.0986      23.8688
##      A12:W1-1      A1-1:W11      A10:W11      A11:W11      A12:W11      A1-1:W12
##      22.1342     -19.7769     -1.0986     -18.1029     -18.1029      19.3616
##      A10:W12      A11:W12      A12:W12
##      -1.0986      25.4176      24.1711
##
## Degrees of Freedom: 39 Total (i.e. Null);  19 Residual
## Null Deviance:      510.1
## Residual Deviance: 11.41    AIC: 123.6
```

Z wykorzystaniem metody krokowej otrzymaliśmy ten sam model, co wyżej.

## Zadanie 11

### Testy

Analogicznie jak w zadaniu 10.

- Model [1 2 3] przeciwko [12 3]

```
m_0 <- glm(Freq ~ D+A1+P, data = df, family = poisson)
m_1 <- glm(Freq ~ D+A1+P+D*A1, data = df, family = poisson)
test <- anova(m_0, m_1)
p_2 <- 1-pchisq(test$Deviance[2], df = test$Df[2])
```

Otrzymana p-wartość 0.2154821 jest większa niż założony poziom istotności, więc nie mamy podstaw do odrzucenia hipotezy zerowej.

- Model [1 2 3] przeciwko [1 23]

```
m_0 <- glm(Freq ~ D+A1+P, data = df, family = poisson)
m_1 <- glm(Freq ~ D+A1+P+P*A1, data = df, family = poisson)
test <- anova(m_0, m_1)
p_2 <- 1-pchisq(test$Deviance[2], df = test$Df[2])
```

Otrzymana p-wartość 0.8022519 jest większa niż założony poziom istotności, więc nie mamy podstaw do odrzucenia hipotezy zerowej.

- Model [1 2 3] przeciwko [13 2]

```
m_0 <- glm(Freq ~ D+A1+P, data = df, family = poisson)
m_1 <- glm(Freq ~ D+A1+P+D*P, data = df, family = poisson)
```

```
test <- anova(m_0, m_1)
p_2 <- 1-pchisq(test$Deviance[2], df = test$Df[2])
```

Otrzymana p-wartość  $3.4586778 \times 10^{-12}$  jest mniejsza niż założony poziom istotności, więc odrzucamy hipotezę zerową. Model [13 2] staje się modelem wyjściowym.

- Model [13 2] przeciwko [12 13]

```
m_0 <- glm(Freq ~ D+A1+P+D*P, data = df, family = poisson)
m_1 <- glm(Freq ~ D+A1+P+D*A1+D*P, data = df, family = poisson)
test <- anova(m_0, m_1)
p_2 <- 1-pchisq(test$Deviance[2], df = test$Df[2])
```

Otrzymana p-wartość 0.2154821 jest większa niż założony poziom istotności, więc nie mamy podstaw do odrzucenia hipotezy zerowej.

- Model [13 2] przeciwko [13 23]

```
m_0 <- glm(Freq ~ D+A1+P+D*P, data = df, family = poisson)
m_1 <- glm(Freq ~ D+A1+P+D*P+A1*P, data = df, family = poisson)
test <- anova(m_0, m_1)
p_2 <- 1-pchisq(test$Deviance[2], df = test$Df[2])
```

Otrzymana p-wartość 0.8022519 jest większa niż założony poziom istotności, więc nie mamy podstaw do odrzucenia hipotezy zerowej.

- Model [13 2] przeciwko [12 23]

```
m_0 <- glm(Freq ~ D+A1+P+D*P, data = df, family = poisson)
m_1 <- glm(Freq ~ D+A1+P+D*A1+A1*P, data = df, family = poisson)
test <- anova(m_0, m_1)
p_2 <- 1-pchisq(test$Deviance[2], df = test$Df[2])
```

Otrzymana p-wartość 1 jest większa niż założony poziom istotności, więc nie mamy podstaw do odrzucenia hipotezy zerowej.

- Model [13 2] przeciwko [12 13 23]

```
m_0 <- glm(Freq ~ D+A1+P+D*P, data = df, family = poisson)
m_1 <- glm(Freq ~ D+A1+P+D*A1+A1*P+D*P, data = df, family = poisson)
test <- anova(m_0, m_1)
p_2 <- 1-pchisq(test$Deviance[2], df = test$Df[2])
```

Otrzymana p-wartość 0.3751853 jest większa niż założony poziom istotności, więc nie mamy podstaw do odrzucenia hipotezy zerowej.

- Model [13 2] przeciwko [123]

```
m_0 <- glm(Freq ~ D+A1+P+D*P, data = df, family = poisson)
m_1 <- glm(Freq ~ D+A1+P+D*A1+A1*P+D*P+A1*P*D, data = df, family = poisson)
test <- anova(m_0, m_1)
p_2 <- 1-pchisq(test$Deviance[2], df = test$Df[2])
```

Otrzymana p-wartość 0.3440413 jest większa niż założony poziom istotności, więc nie mamy podstaw do odrzucenia hipotezy zerowej.

Z przeprowadzonych testów wynika, że model [13 2] najlepiej opisuje nasze dane.

## Kryterium AIC

```
models_AIC <- c(AIC(model_), AIC(model_1), AIC(model_2), AIC(model_3),  
  AIC(model_1_2), AIC(model_1_3), AIC(model_2_3), AIC(model_12),  
  AIC(model_13), AIC(model_23), AIC(model_1_2_3), AIC(model_12_3),  
  AIC(model_13_2), AIC(model_1_23), AIC(model_12_23), AIC(model_13_23),  
  AIC(model_12_13), AIC(model_12_23_13), AIC(model_123))
```

| Model      | Wartość kryterium |
|------------|-------------------|
| [ ]        | 375.2883547       |
| [1]        | 322.5160804       |
| [2]        | 277.1697258       |
| [3]        | 360.2242863       |
| [1 2]      | 224.3974514       |
| [1 3]      | 307.4520119       |
| [2 3]      | 262.1056573       |
| [12]       | 232.9025829       |
| [13]       | 257.0563372       |
| [23]       | 268.4693478       |
| [1 2 3]    | 209.3333829       |
| [12 3]     | 217.8385145       |
| [13 2]     | 158.9377083       |
| [1 23]     | 215.6970734       |
| [12 23]    | 224.2022049       |
| [13 23]    | 165.3013987       |
| [12 13]    | 167.4428395       |
| [12 13 23] | 173.7756383       |
| [123]      | 184.5309303       |

Table 26: Wartości obliczonych kryteriów AIC dla poszczególnych modeli

Najmniejsza wartość kryterium informacyjnego wynosi 158.9377083, a otrzymano ją dla modelu [13 2], czyli tego samego który otrzymaliśmy z wykorzystaniem testów.

## Kryterium BIC

```
models_BIC <- c(BIC(model_), BIC(model_1), BIC(model_2), BIC(model_3),  
  BIC(model_1_2), BIC(model_1_3), BIC(model_2_3), BIC(model_12),  
  BIC(model_13), BIC(model_23), BIC(model_1_2_3), BIC(model_12_3),  
  BIC(model_13_2), BIC(model_1_23), BIC(model_12_23), BIC(model_13_23),  
  BIC(model_12_13), BIC(model_12_23_13), BIC(model_123))
```



| Model      | Wartość kryterium |
|------------|-------------------|
| [ ]        | 376.9772342       |
| [1]        | 329.2715982       |
| [2]        | 285.6141231       |
| [3]        | 363.6020452       |
| [1 2]      | 237.908487        |
| [1 3]      | 315.8964092       |
| [2 3]      | 272.2389341       |
| [12]       | 266.680172        |
| [13]       | 270.5673729       |
| [23]       | 285.3581423       |
| [1 2 3]    | 224.533298        |
| [12 3]     | 253.304983        |
| [13 2]     | 179.2042617       |
| [1 23]     | 237.6525063       |
| [12 23]    | 266.4241913       |
| [13 23]    | 192.32347         |
| [12 13]    | 207.9759464       |
| [12 13 23] | 221.064263        |
| [123]      | 252.0861085       |

Table 27: Wartości obliczonych kryteriów BIC dla poszczególnych modeli

Najmniejsza wartość kryterium informacyjnego wynosi 179.2042617, a otrzymano ją dla modelu [13 2], czyli tego samego który otrzymaliśmy z wykorzystaniem testów i kryterium AIC.

## Metoda krokowa

```
step(model_123)
```

```
## Start:  AIC=184.53
## Freq ~ D + A1 + P + D * A1 + D * P + A1 * P + D * A1 * P
##
##           Df Deviance   AIC
## - D:A1:P 12   13.245 173.78
## <none>         0.000 184.53
##
## Step:  AIC=173.78
## Freq ~ D + A1 + P + D:A1 + D:P + A1:P
##
##           Df Deviance   AIC
## - D:A1 12   28.770 165.30
## - A1:P  4   14.912 167.44
## <none>         13.245 173.78
## - D:P   3   69.671 224.20
##
## Step:  AIC=165.3
## Freq ~ D + A1 + P + D:P + A1:P
##
##           Df Deviance   AIC
## - A1:P  4   30.407 158.94
## <none>         28.770 165.30
## - D:P   3   85.166 215.70
```

```
##
## Step: AIC=158.94
## Freq ~ D + A1 + P + D:P
##
##      Df Deviance   AIC
## <none>      30.407 158.94
## - D:P    3   86.802 209.33
## - A1     4  136.525 257.06

##
## Call: glm(formula = Freq ~ D + A1 + P + D:P, family = poisson, data = df)
##
## Coefficients:
## (Intercept)          DP          DS          DZ          A1-1          A10
##      0.47623      -0.13976      0.04256     -1.74920      0.19416      1.04982
##          A11          A12          PM          DP:PM          DS:PM          DZ:PM
##      1.96611      0.72824     -2.03688      3.39786      1.90335      3.94642
##
## Degrees of Freedom: 39 Total (i.e. Null);  28 Residual
## Null Deviance:      268.8
## Residual Deviance: 30.41      AIC: 158.9
```

Z wykorzystaniem metody krokowej otrzymaliśmy ten sam model, co z wykorzystaniem metod wyżej.